

Aplicação de Algoritmos Genéticos ao TSP

Bruno S. Maion, Lucca A. Neres, Karolayne Dambrosio

Programa de Pós-Graduação em Ciência da Computação
Universidade Estadual do Oeste do Paraná



unioeste


Universidade Estadual do Oeste do Paraná



PPGComp

Introdução

- O **Problema do Caixeiro Viajante (TSP)** é um desafio clássico de otimização combinatória, cujo objetivo é encontrar o ciclo de menor custo que visita todas as cidades exatamente uma vez (Arenales et al., 2015).
- NP-difícil
- Objetivo: avaliar quatro variantes de AGs com *DeleteCross* e **clusterização**.
- Instâncias *TSPLIB*.
- Métricas de avaliação: incluem **qualidade da solução** (menor fitness) e **tempo de execução**.



Commis-Voyageur Tour (1832)

Ambiente Computacional

- **CPU:** Intel Core i5-13600KF (14 Núcleos/20 Threads, até 5.1 GHz)
- **RAM:** 32GB DDR5 6000MHz
- **OS:** Ubuntu 24.04.2 LTS
- **Linguagem:** Python 3.12.3

Parâmetros Comuns

- **Gerações:** 500
- **População:** 100
- **Elitismo:** 2.5%
- **Seleção:** Torneio ($k = 3$)
- **Cruzamento:** Operador OX
- **Execuções:** 20 por instância

- ❶ **AG Original:** Mutação de Dois Pontos (Swap Mutation).
- ❷ **AG 1DeleteCross:** Utiliza o operador **DeleteCross** (remove um cruzamento).
- ❸ **AG 1DC-Solucao-Cluster2x2:**
 - Decomposição em $N = 2$ clusters;
 - **AG 1DeleteCross** em cada cluster;
 - Concatenação das **melhores rotas** parciais.
- ❹ **AG 1DC-AG-Cluster2x2:**
 - Decomposição em $N = 2 \times 2$ clusters;
 - **AG 1DeleteCross** em cada cluster;
 - Agrupamento das populações finais;
 - Segundo **AG 1DeleteCross** no problema completo.

Instâncias de Teste (TSPLIB)

- berlin52 (**52** cidades)
- ch150 (**150** cidades)
- rd400 (**400** cidades)

Métricas de Desempenho


- **Fitness** Distância Total do Percurso (Minimização)
- **Fitness Inicial Médio** (`fit_inicial`)
- **Fitness Melhor Médio** (`fit_melhor`)
- **Tempo Médio** (`tempo_execucao`)
- **Ganho Relativo Médio (%)**:

$$\text{Ganho Relativo} = \frac{\text{Fit Inicial} - \text{Fit Final}}{\text{Fit Inicial}} \times 100\%$$

Metodologia

Estratégia de Clusterização

- Estratégia que permite tratar **subgrupos de pontos** de forma independente.
- Os AGs são aplicados em cada **cluster** (subproblema).
- Promove uma **exploração local** (exploração) antes da otimização global.
- **Junção de Clusters:** As soluções parciais são combinadas através do **ponto mais próximo** entre clusters consecutivos.




rd400 em 2×2 clusters.

- **Função objetiva** — O cálculo do *fitness* pela função objetiva é realizado sempre que necessário, em vez de consultar uma matriz de adjacência pré-calculada. Assim, sendo adequado para instâncias menores, mas penalizando o desempenho em instâncias maiores.
- **Operador delete-cross** — O operador é aplicado n vezes por geração, onde n corresponde a aproximadamente 5% do tamanho da instância (taxa de aplicação do *delete-cross*). Além disso, ele é sempre aplicado no início da solução.
- **Junção de clusters** — Os grupos são combinados em uma solução global utilizando o ponto mais próximo entre clusters consecutivos. Para cada par de clusters, é identificado o ponto em um cluster que está mais próximo de um ponto do cluster seguinte, e a sequência de pontos é reorganizada para minimizar o salto entre eles.

Resultados - Berlin52


Tempos

Tempo de Execução — berlin52




Resultados - Berlin52

Ganho Relativo




Resultados - Ch150

Tempos




Resultados - Ch150

Ganho Relativo




Resultados - Rd400

Tempos



Resultados - Rd400

Ganho Relativo




Resultados

Resultados Médios por Grafo

Grafo	Algoritmo	Fit Inicial	Fit Melhor	T. Médio (s)	Ganho Rel. (%)
berlin52	Original	25874.49	13453.63	0.89	47.95
berlin52	1DeleteCross	25920.39	9483.37	2.81	63.36
berlin52	1DC-Solucao-Cluster2x2	26040.31	10662.71	2.72	59.04
berlin52	1DC-AG-Cluster2x2	25875.96	9540.23	6.83	63.12
ch150	Original	49142.68	28886.39	4.25	41.20
ch150	1DeleteCross	49201.46	19481.41	12.90	60.39
ch150	1DC-Solucao-Cluster2x2	49167.15	9194.53	13.56	81.30
ch150	1DC-AG-Cluster2x2	49237.51	9248.64	41.09	81.21
rd400	Original	200077.12	126943.52	24.93	36.55
rd400	1DeleteCross	200834.91	82159.24	55.36	59.09
rd400	1DC-Solucao-Cluster2x2	200579.27	37108.09	29.82	81.50
rd400	1DC-AG-Cluster2x2	199967.90	36727.31	132.68	81.63

Resultados

Resultados Médios por Grafo



- O **Algoritmo Original** foi consistentemente o pior em todas as instâncias em termos de qualidade da solução (`fit_melhor` e `ganho_relativo`), apesar do menor tempo de execução.
- O **1DeleteCross** foi o melhor para a menor instância (`berlin52`), com o maior ganho relativo (63.36%).
- Para instâncias maiores (`ch150` e `rd400`), as abordagens com **clusterização** apresentaram os **maiores ganhos relativos** (acima de 81%).
- Os ganhos de `1DC-Solucao-Cluster2x2` e `1DC-AG-Cluster2x2` são muito próximos, porém:
 - `1DC-Solucao-Cluster2x2` foi significativamente mais rápido para `ch150` (13.56s vs 41.09s).
 - `1DC-AG-Cluster2x2` obteve a melhor solução geral para `rd400`.

- **AG Original:** o mais rápido, porém com **exploração limitada**, obtendo as piores soluções finais.
- **1DeleteCross:** eficiente para instâncias pequenas (berlin52), com bom ganho relativo e tempo moderado.
- **Clusterização (1DC-Solucao e 1DC-AG):**
 - Apresentaram os **maiores ganhos relativos** e melhores soluções para **instâncias maiores**.
 - O **tempo de execução** foi significativamente maior.
 - A decomposição em subproblemas permitiu uma **melhor exploração** do espaço de busca em problemas complexos.

Referências I

M. Arenales, R. Morabito, V. Armentano, and H. Yanasse. *Pesquisa Operacional: Para cursos de engenharia*. Elsevier Brasil, 2015. ISBN 9788535281835.